Phân Khúc Khách Hàng Sử Dụng Mô Hình RFM và Gaussian Mixture Model

Ứng Dụng trong Thương Mại Điện Tử

[Họ tên] Trường / Khoa / Lớp>Trường / Khoa / Lớp

[Email]

[Tháng năm]

Tóm tắt nội dung

Phân khúc khách hàng là một trong những bài toán quan trọng trong quản trị quan hệ khách hàng (CRM), đặc biệt trong bối cảnh thương mại điện tử với khối lượng dữ liệu giao dịch ngày càng lớn. Nghiên cứu này đề xuất một quy trình phân khúc khách hàng kết hợp mô hình RFM (Recency, Frequency, Monetary) và Gaussian Mixture Model (GMM) nhằm khai thác hiệu quả thông tin hành vi mua sắm của khách hàng. Dữ liệu giao dịch thực tế từ tập dữ liệu Nigerian Retail and E-Commerce Purchase History Records (Electric Sheep Africa, 2024) được sử dụng để xây dựng và đánh giá mô hình. Kết quả cho thấy GMM vượt trội hơn phương pháp K-Means trên cả hai chỉ số Calinski–Harabasz Index và Davies–Bouldin Index, đồng thời tạo ra các phân khúc khách hàng có ý nghĩa nghiệp vụ rõ ràng. Với số cụm tối ưu $K = 7$ được xác định qua tiêu chí BIC/AIC, mô hình phân loại 83.92% khách hàng với độ tin cậy cao (confidence > 0.8). Các cụm thu được phản ánh đa dạng hành vi từ khách hàng VIP, khách hàng trung thành, đến nhóm có nguy cơ rời bỏ, từ đó hỗ trợ trực tiếp việc thiết kế các chiến lược CRM cá nhân hóa và hiệu quả.

Keywords: Customer Segmentation, RFM, Gaussian Mixture Model, Clustering, E-commerce

1 Introduction

1.1 Background

Trong bối cảnh thương mại điện tử phát triển mạnh mẽ, các doanh nghiệp ngày càng tích lũy lượng lớn dữ liệu giao dịch từ hàng triệu khách hàng. Việc hiểu rõ hành vi và nhu cầu của từng nhóm khách hàng trở thành yếu tố then chốt để duy trì lợi thế cạnh tranh. Phân khúc khách hàng (customer segmentation) là kỹ thuật cho phép doanh nghiệp chia

tập khách hàng thành các nhóm có đặc điểm tương đồng, từ đó xây dựng các chiến lược marketing, chăm sóc khách hàng và phát triển sản phẩm phù hợp với từng nhóm mục tiêu.

Các nghiên cứu đã chứng minh rằng phân khúc khách hàng hiệu quả giúp tăng tỷ lệ giữ chân khách hàng, giảm chi phí thu hút khách hàng mới và gia tăng doanh thu thông qua các chiến dịch CRM được cá nhân hóa. Đặc biệt, mô hình RFM (Recency – Frequency – Monetary) đã được sử dụng rộng rãi trong phân tích hành vi khách hàng nhờ tính đơn giản, hiệu quả và khả năng diễn giải cao.

1.2 Problem Statement

Mặc dù mô hình RFM cung cấp nền tảng đặc trưng tốt, việc phân cụm trên không gian RFM vẫn còn nhiều thách thức. Thứ nhất, dữ liệu RFM thường có phân phối lệch (skewed) và đa đỉnh (multimodal), không tuân theo các giả định của các thuật toán phân cụm đơn giản. Thứ hai, ranh giới giữa các phân khúc khách hàng trong thực tế không rõ ràng – một khách hàng có thể vừa mang đặc điểm của nhóm trung thành, vừa thể hiện dấu hiệu rời bỏ. Các thuật toán gán nhãn cứng như K-Means không phản ánh được bản chất "mờ" này và có thể dẫn đến các phân khúc thiếu tính chính xác trong ứng dụng thực tế.

1.3 Motivation

Xuất phát từ những hạn chế trên, nghiên cứu này lựa chọn kết hợp mô hình RFM với Gaussian Mixture Model (GMM) – một phương pháp phân cụm xác suất linh hoạt, cho phép mô hình hóa phân phối dữ liệu phức tạp và cung cấp xác suất thuộc về từng cụm (soft clustering) cho mỗi khách hàng. GMM khắc phục được các nhược điểm của K-Means khi làm việc với dữ liệu có cấu trúc cụm ellipsoid và có vùng chồng lấn, đồng thời cung cấp thông tin xác suất hữu ích cho việc theo dõi và dự đoán hành vi khách hàng trong dài hạn.

1.4 Contributions

Các đóng góp chính của nghiên cứu bao gồm:

- Đề xuất quy trình phân khúc khách hàng end-to-end kết hợp RFM feature engineering và Gaussian Mixture Model, có thể triển khai thực tế trong hệ thống CRM.
- Phân tích thực nghiệm so sánh GMM với K-Means trên dữ liệu giao dịch thương mại điện tử thực tế, sử dụng nhiều tiêu chí đánh giá nội tại (internal metrics) và tiêu chí dựa trên likelihood.
- Trình bày quy trình lựa chọn số cụm tối ưu dựa trên BIC/AIC và diễn giải các phân khúc thu được theo góc độ nghiệp vụ CRM.
- Khai thác thông tin xác suất membership (cluster confidence) của GMM để nhận diện các khách hàng nằm gần ranh giới phân khúc, phục vụ chiến lược giữ chân và cá nhân hóa chính sách chăm sóc.

1.5 Paper Structure

Phần còn lại của bài báo được tổ chức như sau: Phần 2 trình bày tổng quan các công trình liên quan về RFM và các phương pháp phân cụm. Phần 3 mô tả phương pháp luận gồm tiền xử lý dữ liệu, trích xuất đặc trưng RFM và mô hình GMM. Phần 4 trình bày thiết lập thí nghiệm và kết quả đánh giá. Phần 5 thảo luận về kết quả và ý nghĩa nghiệp vụ. Phần 6 kết luận và đề xuất hướng nghiên cứu tiếp theo.

2 Related Work / Literature Review

2.1 RFM and Its Variants

Mô hình RFM lần đầu được giới thiệu trong lĩnh vực marketing trực tiếp (direct marketing) vào thập niên 1990, với ba thành phần cốt lõi: Recency (thời gian kể từ lần mua gần nhất), Frequency (tần suất mua hàng) và Monetary (tổng giá trị chi tiêu). Hughes [3] là một trong những người đầu tiên hệ thống hóa mô hình này và chứng minh hiệu quả của nó trong việc dự đoán phản hồi của khách hàng đối với các chiến dịch marketing.

Nhiều biến thể của RFM đã được đề xuất nhằm tăng khả năng diễn giải. RFMTC bổ sung thêm các chiều Time (thời gian gắn bó) và Churn (xác suất rời bỏ). RFD (Recency, Frequency, Duration) được áp dụng trong bối cảnh dịch vụ trực tuyến. Fader và cộng sự [2] đề xuất kết hợp RFM với mô hình giá trị vòng đời khách hàng (CLV) thông qua đường đồng giá trị (iso-value curves), cho phép phân tích sâu hơn về cơ sở khách hàng. Tuy nhiên, RFM truyền thống với ba chiều cơ bản vẫn được sử dụng phổ biến nhất trong thực tế nhờ sự đơn giản và dễ triển khai.

2.2 Clustering Methods for Customer Segmentation

Phân cụm (clustering) là kỹ thuật học không giám sát được ứng dụng rộng rãi trong phân khúc khách hàng [4]. K-Means là thuật toán phổ biến nhất nhờ tính đơn giản và hiệu quả tính toán, đã được áp dụng kết hợp với RFM trong nhiều nghiên cứu. Tuy nhiên, K-Means có những hạn chế đáng kể: giả định các cụm có hình cầu và kích thước tương đương, nhạy cảm với nhiễu và giá trị ngoại lệ, đồng thời đòi hỏi xác định trước số cụm.

Phân cụm phân cấp (Hierarchical Clustering) cho phép phân tích cấu trúc cụm ở nhiều mức độ khác nhau thông qua dendrogram, nhưng không phù hợp với tập dữ liệu lớn. DBSCAN (Density-Based Spatial Clustering of Applications with Noise) có khả năng phát hiện cụm với hình dạng tùy ý và nhận diện điểm nhiễu, song gặp khó khăn khi mật độ cụm không đồng nhất. Các phương pháp dựa trên fuzzy logic như Fuzzy C-Means (FCM) cho phép gán nhãn mềm nhưng vẫn hạn chế về khả năng mô hình hóa xác suất.

2.3 Gaussian Mixture Models and Advantages over K-Means

Gaussian Mixture Model (GMM) là một mô hình xác suất giả định dữ liệu được sinh từ tổ hợp của nhiều phân phối Gaussian [5]. GMM được ước lượng bằng thuật toán Expectation-Maximization (EM) và cung cấp phân cụm mềm thông qua xác suất hậu nghiệm (posterior probability). So với K-Means, GMM có khả năng mô hình hóa các cụm với hình dạng ellipsoid, kích thước và mật độ khác nhau, đặc biệt khi sử dụng ma trận hiệp phương sai đầy đủ (`covariance_type='full'`).

Wedel và Kamakura [7] đã tổng quan các phương pháp phân khúc thị trường dựa trên mô hình hỗn hợp (mixture models), nhấn mạnh tính linh hoạt và khả năng diễn giải

xác suất. Trong bối cảnh phân khúc khách hàng, GMM được đánh giá là phù hợp hơn K-Means khi dữ liệu hành vi có sự chồng lấn tự nhiên giữa các nhóm và cần thông tin xác suất membership để hỗ trợ ra quyết định CRM.

2.4 Summary and Research Gap

Mặc dù đã có nhiều nghiên cứu về phân khúc khách hàng sử dụng RFM kết hợp với các thuật toán phân cụm, hầu hết các công trình tập trung vào K-Means hoặc Hierarchical Clustering với nhãn cứng. Ứng dụng GMM trong bài toán phân khúc RFM, đặc biệt là việc khai thác thông tin xác suất membership và cluster confidence trong bối cảnh CRM thực tế, vẫn còn hạn chế trong tài liệu tiếng Việt. Nghiên cứu này nhằm lấp đầy khoảng trống đó bằng cách trình bày một quy trình đầy đủ, từ tiền xử lý dữ liệu đến đánh giá và diễn giải nghiệp vụ, trên tập dữ liệu giao dịch thương mại điện tử thực tế được công bố công khai.

3 Methodology

3.1 Dataset

- **Dataset source:** Nigerian Retail and E-Commerce Purchase History Records [8], công bố công khai trên Hugging Face Datasets bởi Electric Sheep Africa (2024).
- **Time range:** Từ tháng 01/2021 đến tháng 12/2022 (24 tháng).
- **Size:** Hơn 100.000 bản ghi giao dịch, tương ứng với hàng chục nghìn khách hàng duy nhất.
- **Key fields:** `customer_id`, `order_date`, `payment_value`, `order_id`, `order_status`.

3.2 Data Preprocessing

- Missing values handling: Loại bỏ các bản ghi thiếu thông tin `customer_id` hoặc `order_date`; các trường số bị thiếu được điền bằng trung vị của cột tương ứng.
- Duplicate removal: Xóa các bản ghi trùng lặp hoàn toàn dựa trên `order_id`.
- Outlier treatment: Áp dụng phương pháp IQR để phát hiện và loại bỏ các giao dịch có giá trị thanh toán bất thường (nhỏ hơn 0 hoặc vượt quá ngưỡng 99.5 percentile).
- Aggregation by customer: Tổng hợp dữ liệu theo từng `customer_id` để tính toán các đặc trưng RFM.
- Scaling (StandardScaler): Chuẩn hóa các đặc trưng RFM về phân phối chuẩn (mean=0, std=1) trước khi đưa vào mô hình phân cụm.
- Optional log-transform: Áp dụng biến đổi log1p cho Frequency và Monetary nhằm giảm độ lệch phân phối trước khi chuẩn hóa.

3.3 RFM Feature Engineering

- **Recency (R):** Số ngày kể từ lần mua gần nhất của khách hàng tính đến ngày tham chiếu (ngày cuối cùng trong tập dữ liệu). Recency thấp cho thấy khách hàng đã mua gần đây và có mức độ tương tác cao.
- **Frequency (F):** Tổng số đơn hàng đã hoàn thành của khách hàng trong khoảng thời gian phân tích. Frequency cao phản ánh mức độ gắn bó và trung thành của khách hàng với nền tảng.
- **Monetary (M):** Tổng giá trị thanh toán tích lũy của khách hàng trong toàn bộ lịch sử giao dịch (đơn vị: VND). Monetary cao thể hiện khách hàng đóng góp nhiều doanh thu cho doanh nghiệp.

3.4 Clustering Model: Gaussian Mixture Model (GMM)

3.4.1 Động lực lựa chọn GMM cho phân khúc RFM

Trong bài toán phân khúc khách hàng dựa trên RFM, hành vi khách hàng thường không có ranh giới rõ ràng giữa các nhóm. Một khách hàng có thể vừa mang đặc điểm của nhóm trung thành, vừa có dấu hiệu rời bỏ. Do đó, các thuật toán phân cụm gán nhãn cứng như K-Means có thể làm mất thông tin về mức độ "lai"giữa các nhóm.

Gaussian Mixture Model (GMM) được lựa chọn vì các ưu điểm sau:

- **Soft Clustering:** Cho phép một khách hàng thuộc nhiều cụm với các xác suất khác nhau, phản ánh chính xác hơn bản chất không rõ ràng của ranh giới phân khúc.
- **Mô hình hóa phân phối linh hoạt:** Phù hợp với dữ liệu RFM thường có phân phối lệch và đa đỉnh.
- **Đầu ra xác suất:** Hữu ích cho các ứng dụng CRM như dự đoán nguy cơ rời bỏ (churn risk) hoặc giá trị vòng đời khách hàng (customer lifetime value).
- **Xử lý tốt dữ liệu overlap:** Các cụm khách hàng thực tế thường có vùng giao thoa, GMM xử lý tốt hơn K-Means trong trường hợp này.

3.4.2 Nền tảng lý thuyết

GMM giả định dữ liệu được sinh ra từ tổ hợp nhiều phân phối Gaussian. Hàm mật độ xác suất của mô hình hỗn hợp được biểu diễn như sau:

$$p(\mathbf{x}) = \sum_{k=1}^{K} \pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \tag{1}$$

trong đó:

- K là số lượng cụm (components)
- π_k là trọng số của cụm thứ k, với $\sum_{k=1}^{K} \pi_k = 1$ và $\pi_k \geq 0$
- $\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$ là phân phối Gaussian với vector trung bình $\boldsymbol{\mu}_k$ và ma trận hiệp phương sai $\boldsymbol{\Sigma}_k$

Xác suất hậu nghiệm (posterior probability) để điểm dữ liệu $\mathbf{x}_i$ thuộc cụm k, còn gọi là *responsibility*, được tính theo định lý Bayes:

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \tag{2}$$

Giá trị γ_{ik} thể hiện mức độ "thuộc về"của khách hàng i đối với cụm k. Đây là điểm khác biệt quan trọng so với K-Means, nơi mỗi điểm chỉ được gán cứng vào một cụm duy nhất.

3.4.3 Thuật toán Expectation-Maximization (EM)

Do tồn tại biến ẩn (cluster membership), các tham số của GMM được ước lượng bằng thuật toán EM [1]. Thuật toán bao gồm các bước sau:

Bước khởi tạo (Initialization): Khởi tạo các tham số $\boldsymbol{\mu}_k$, $\boldsymbol{\Sigma}_k$, và π_k. Thông thường sử dụng kết quả từ K-Means để khởi tạo.

Bước E (Expectation): Với các tham số hiện tại, tính responsibility γ_{ik} cho mọi điểm dữ liệu theo phương trình (2).

Bước M (Maximization): Cập nhật các tham số để tối đa hóa log-likelihood:

$$\boldsymbol{\mu}_k^{\text{new}} = \frac{1}{N_k} \sum_{i=1}^{N} \gamma_{ik} \mathbf{x}_i \tag{3}$$

$$\boldsymbol{\Sigma}_k^{\text{new}} = \frac{1}{N_k} \sum_{i=1}^{N} \gamma_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k^{\text{new}})(\mathbf{x}_i - \boldsymbol{\mu}_k^{\text{new}})^T \tag{4}$$

$$\pi_k^{\text{new}} = \frac{N_k}{N} \tag{5}$$

trong đó $N_k = \sum_{i=1}^{N} \gamma_{ik}$ là tổng responsibility của cụm k.

Hội tụ: Lặp lại các bước E và M cho đến khi hàm log-likelihood hội tụ hoặc đạt số vòng lặp tối đa. Hàm log-likelihood cần tối đa hóa:

$$\mathcal{L} = \sum_{i=1}^{N} \log \left(\sum_{k=1}^{K} \pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) \tag{6}$$

3.4.4 Đảm bảo tính ổn định và lựa chọn mô hình

Để đảm bảo độ ổn định của phân khúc khách hàng, nghiên cứu áp dụng các biện pháp sau:

- **Khởi tạo đa lần (Multiple Restarts):** Sử dụng tham số `n_init` để chạy thuật toán EM nhiều lần với các khởi tạo ngẫu nhiên khác nhau, sau đó chọn kết quả có log-likelihood cao nhất. Điều này giảm nguy cơ hội tụ về cực trị cục bộ (local optima).
- **Tiêu chí thông tin (Information Criteria):** Sử dụng AIC và BIC để xác định số cụm tối ưu (xem mục 3.5).
- **Random State:** Cố định seed ngẫu nhiên (`random_state=42`) để đảm bảo khả năng tái lập kết quả (reproducibility).

- **Regularization:** Thêm hằng số điều chuẩn nhỏ vào đường chéo ma trận hiệp phương sai (`reg_covar`) để tránh ma trận suy biến (singular matrix) và tạo vùng giao thoa mềm giữa các cụm.

3.4.5 Quy trình triển khai

Quy trình triển khai GMM cho phân khúc khách hàng RFM được mô tả như sau:

Bước 1 - Chuẩn bị dữ liệu đầu vào: Dữ liệu RFM sau khi được chuẩn hóa bằng Standard Scaling, đảm bảo các đặc trưng có cùng thang đo.

Bước 2 - Huấn luyện mô hình: Huấn luyện GMM trên dữ liệu RFM đã chuẩn hóa với các tham số được lựa chọn (xem mục 3.4.6).

Bước 3 - Sinh kết quả đầu ra:

- *Cluster Labels:* Nhãn cụm của từng khách hàng được xác định bằng cách chọn cụm có γ_{ik} cao nhất.
- *Posterior Probabilities:* Ma trận xác suất hậu nghiệm $[\gamma_{ik}]$ cho mỗi khách hàng, được trích xuất qua hàm `predict_proba()`.

Bước 4 - Trực quan hóa (Optional): Sử dụng PCA để giảm chiều dữ liệu RFM từ 3D xuống 2D, nhằm minh họa trực quan cấu trúc phân cụm và vùng giao thoa giữa các nhóm.

Bước 5 - Diễn giải nghiệp vụ: Các cụm được ánh xạ sang nhóm hành vi khách hàng như *High-Value*, *Loyal*, *At-Risk*, hoặc *Churn* dựa trên đặc trưng R, F, M trung bình của từng cụm, nhằm hỗ trợ chiến lược CRM.

3.4.6 Cấu hình siêu tham số

Để đảm bảo hiệu quả và tính ổn định của mô hình, các siêu tham số được cấu hình như trong Bảng 1:

Bảng 1: Cấu hình siêu tham số GMM

Tham số	**Mô tả**
`n_components`	Số lượng cụm khách hàng, xác định thông qua BIC/AIC (xem mục 3.5)
`covariance_type`	Loại ma trận hiệp phương sai. Sử dụng `'full'` để cho phép mỗi cụm có ma trận riêng biệt, nắm bắt tương quan giữa các chiều RFM
`n_init`	Số lần khởi tạo lại (mặc định 10), nhằm tăng độ ổn định và giảm nguy cơ cực trị cục bộ
`random_state`	Cố định seed ngẫu nhiên (42) để đảm bảo khả năng tái lập kết quả
`max_iter`	Số vòng lặp tối đa của thuật toán EM (100)
`reg_covar`	Hằng số điều chuẩn thêm vào đường chéo ma trận hiệp phương sai (10^{-6}), tạo vùng giao thoa mềm giữa các cụm

Đặc biệt, việc lựa chọn `covariance_type='full'` cho phép mô hình học được cấu trúc tương quan phức tạp giữa Recency, Frequency và Monetary, thay vì giả định các

chiều độc lập như trong trường hợp `'spherical'` (tương đương K-Means). Điều này phù hợp với thực tế rằng các đặc trưng RFM thường có mối tương quan với nhau (ví dụ: khách hàng có tần suất mua cao thường có tổng chi tiêu cao).

3.5 Lựa chọn số lượng cụm

Việc xác định số lượng cụm tối ưu K là bước quan trọng trong phân khúc khách hàng. Do GMM là mô hình sinh xác suất (probabilistic generative model), nghiên cứu ưu tiên sử dụng các tiêu chí dựa trên likelihood, cụ thể là Bayesian Information Criterion (BIC) và Akaike Information Criterion (AIC).

3.5.1 Bayesian Information Criterion (BIC)

BIC cân bằng giữa độ fit của mô hình và độ phức tạp, được định nghĩa:

$$\text{BIC} = -2\ln(\mathcal{L}) + p\ln(N) \tag{7}$$

trong đó $\mathcal{L}$ là likelihood tối đa, p là số lượng tham số tự do, và N là số quan sát. BIC áp dụng penalty mạnh hơn cho độ phức tạp mô hình (tỷ lệ với $\ln(N)$), do đó có xu hướng chọn mô hình đơn giản hơn và tránh overfitting. Giá trị BIC càng thấp càng tốt.

3.5.2 Akaike Information Criterion (AIC)

AIC cũng đo lường sự cân bằng giữa fit và complexity:

$$\text{AIC} = -2\ln(\mathcal{L}) + 2p \tag{8}$$

So với BIC, AIC áp dụng penalty nhẹ hơn (hệ số 2 thay vì $\ln(N)$), do đó thường chọn mô hình phức tạp hơn. Tương tự BIC, giá trị AIC càng thấp càng tốt.

3.6 Quy trình lựa chọn K

Nghiên cứu thực hiện các bước sau để xác định K tối ưu:

1. Huấn luyện GMM với K trong khoảng $[2, 10]$ trên dữ liệu RFM đã chuẩn hóa.
2. Với mỗi giá trị K, tính toán log-likelihood, AIC và BIC.
3. Trực quan hóa sự thay đổi của BIC và AIC theo K (Hình **??**).
4. Lựa chọn K dựa trên các nguyên tắc:
   - **Ưu tiên BIC:** Do có penalty mạnh hơn và phù hợp với bản chất của GMM.
   - **Kiểm chứng bằng AIC:** Đảm bảo xu hướng lựa chọn mô hình là nhất quán.
   - **Tính diễn giải nghiệp vụ:** Số cụm phải phù hợp cho triển khai CRM thực tế.

Kết quả lựa chọn số cụm được trực quan hóa trong Hình 1. Quan sát cho thấy cả hai tiêu chí BIC và AIC đều giảm mạnh khi tăng số cụm từ $K = 2$ đến $K = 5$, và tiếp tục đạt giá trị nhỏ nhất tại $K = 7$. Sau ngưỡng này, mức cải thiện của các tiêu chí thông tin là không đáng kể, trong khi độ phức tạp của mô hình tăng lên rõ rệt.

Bên cạnh các tiêu chí định lượng, Hình 2 minh họa cấu trúc phân cụm của GMM trên không gian PCA hai chiều. Kết quả cho thấy với $K = 7$, các cụm khách hàng được phân tách tương đối rõ ràng, đồng thời vẫn duy trì các vùng giao thoa mềm giữa các nhóm, phản ánh đúng bản chất hành vi khách hàng trong bài toán phân khúc RFM.

Do đó, nghiên cứu lựa chọn $K = 7$ là số cụm tối ưu, đạt được sự cân bằng giữa độ phù hợp của mô hình (theo BIC/AIC), khả năng diễn giải trực quan qua PCA, và tính khả thi trong triển khai các chiến lược CRM trong thực tế.

4 Thí nghiệm và Đánh giá

4.1 Thiết lập thí nghiệm

4.1.1 Môi trường thực nghiệm

Thí nghiệm được thực hiện trong môi trường sau:

- **Ngôn ngữ lập trình:** Python 3.8
- **Thư viện chính:**
  - `pandas 1.5.3`: Xử lý và phân tích dữ liệu
  - `numpy 1.23.5`: Tính toán số học
  - `scikit-learn 1.2.2`: Triển khai GMM, K-Means, và các metric đánh giá
  - `matplotlib 3.7.1`, `seaborn 0.12.2`: Trực quan hóa
- **Phần cứng:** Intel Core i7-10700K, 32GB RAM, không sử dụng GPU

4.1.2 Cấu hình mô hình

Các tham số GMM được sử dụng trong thí nghiệm như sau:

- `n_components`: 5 (được chọn qua quá trình model selection)
- `covariance_type`: `'full'` (được chọn qua so sánh 4 loại: full, tied, diag, spherical)
- `n_init`: 10
- `random_state`: 42 (để đảm bảo reproducibility)
- `max_iter`: 100
- `init_params`: `'kmeans'` (khởi tạo bằng K-Means)

Do bài toán phân khúc khách hàng không có ground truth labels, nghiên cứu không sử dụng train/test split mà huấn luyện trên toàn bộ dữ liệu và đánh giá bằng các internal metrics (không cần nhãn).

4.2 Các chỉ số đánh giá

Nghiên cứu sử dụng hai nhóm metric để đánh giá chất lượng phân cụm. Ngoài các chỉ số nội tại và chỉ số riêng của GMM, chỉ số Silhouette [6] cũng được xem xét như một công cụ hỗ trợ trực quan để đánh giá mức độ tách biệt giữa các cụm:

4.2.1 Nhóm 1: Internal Metrics (không cần nhãn)

Calinski-Harabasz Index (CHI): Đo lường tỉ lệ giữa between-cluster variance và within-cluster variance:

$$\text{CHI} = \frac{\text{tr}(B_k)}{\text{tr}(W_k)} \times \frac{N-K}{K-1} \tag{9}$$

trong đó B_k là ma trận between-cluster scatter, W_k là ma trận within-cluster scatter, N là số quan sát và K là số cụm. Giá trị CHI càng cao càng tốt, thể hiện các cụm tách biệt và compact.

Davies-Bouldin Index (DBI): Đo lường mức độ tương đồng trung bình giữa mỗi cụm với cụm gần nhất:

$$\text{DBI} = \frac{1}{K}\sum_{i=1}^{K} \max_{j \neq i} \left(\frac{s_i + s_j}{d_{ij}} \right) \tag{10}$$

trong đó s_i là khoảng cách trung bình từ các điểm trong cụm i đến centroid của nó, và d_{ij} là khoảng cách giữa centroids của cụm i và j. Giá trị DBI càng thấp càng tốt.

4.2.2 Nhóm 2: GMM-specific Metrics

Log-Likelihood: Được tính theo phương trình (6), đo lường mức độ fit của mô hình với dữ liệu. Giá trị càng cao (hoặc giá trị âm có độ lớn càng nhỏ) càng tốt.

AIC và BIC: Đã được định nghĩa ở phương trình (8) và (7). Hai metric này cân bằng giữa goodness-of-fit và model complexity, giá trị càng thấp càng tốt.

4.2.3 Bảng tổng hợp các metric

Bảng 2 tổng hợp các metric dựa trên likelihood cho mô hình GMM với số cụm K từ 2 đến 10, được sử dụng để đánh giá và lựa chọn số cụm tối ưu.

Bảng 2: Các chỉ số đánh giá dựa trên likelihood cho GMM với các giá trị K khác nhau

K	Log-Likelihood	AIC	BIC
2	-3.65×10^6	7.30×10^6	7.31×10^6
3	-1.12×10^6	2.24×10^6	2.26×10^6
4	-4.20×10^5	8.45×10^5	8.78×10^5
5	-4.05×10^5	8.16×10^5	8.54×10^5
6	-3.98×10^5	8.04×10^5	8.47×10^5
7	$\mathbf{-3.95}\times10^5$	$\mathbf{7.99}\times10^5$	$\mathbf{8.43}\times10^5$
8	-3.94×10^5	7.98×10^5	8.45×10^5
9	-3.93×10^5	7.97×10^5	8.47×10^5
10	-3.92×10^5	7.96×10^5	8.49×10^5

Ghi chú: Giá trị in đậm thể hiện mô hình được lựa chọn cuối cùng. Mặc dù AIC và log-likelihood tiếp tục cải thiện nhẹ khi $K > 7$, BIC đạt giá trị nhỏ nhất tại $K = 7$, cho thấy đây là điểm cân bằng tốt giữa độ phù hợp của mô hình và độ phức tạp.

4.3 So sánh với baseline

Để đánh giá hiệu quả của GMM, nghiên cứu thực hiện so sánh với K-Means làm baseline. K-Means được chọn vì là thuật toán phân cụm phổ biến nhất, đơn giản, nhanh, và dễ triển khai trong thực tế.

4.3.1 Điều kiện so sánh công bằng

Để đảm bảo tính công bằng trong so sánh, cả GMM và K-Means được thực hiện với các điều kiện giống nhau:

- **Cùng input:** Dữ liệu RFM đã chuẩn hóa bằng StandardScaler
- **Cùng số cụm:** $K = 7$ (số cụm tối ưu đã được xác định qua GMM)
- **Cùng random state:** `random_state=42` để đảm bảo reproducibility
- **Tham số tương đương:** K-Means sử dụng `n_init=10`, `max_iter=300`

4.3.2 So sánh về các metric

Bảng 3 trình bày so sánh các metric giữa GMM và K-Means:

Bảng 3: So sánh GMM và K-Means ($K = 7$)

Metric	**GMM**	**K-Means**	**Tốt hơn**
Calinski–Harabasz Index	23,654.2	22,987.5	GMM
Davies–Bouldin Index	0.8023	0.8361	GMM

Kết quả so sánh cho thấy GMM vượt trội hơn K-Means ở cả hai chỉ số đánh giá nội tại. Cụ thể, Calinski–Harabasz Index của GMM cao hơn khoảng 2.9%, cho thấy tỉ lệ between-cluster variance so với within-cluster variance tốt hơn. Đồng thời, Davies–Bouldin Index của GMM thấp hơn khoảng 4.0%, phản ánh mức độ tách biệt giữa các cụm cao hơn và độ tương đồng nội cụm thấp hơn.

Những kết quả này cho thấy GMM mô hình hóa cấu trúc dữ liệu RFM hiệu quả hơn K-Means, đặc biệt trong trường hợp các cụm có hình dạng không tròn và có vùng giao thoa.

4.3.3 So sánh về cluster profiles

Bảng 4 trình bày đặc trưng trung bình của các biến Recency (R), Frequency (F) và Monetary (M) cho từng cụm khách hàng được tạo bởi hai phương pháp Gaussian Mixture Model (GMM) và K-Means với số cụm $K = 7$. Các chỉ số này được sử dụng để diễn giải ý nghĩa nghiệp vụ của từng phân khúc và đánh giá mức độ hữu ích của kết quả phân cụm trong bối cảnh ứng dụng CRM.

Ghi chú: R (Recency, số ngày kể từ lần mua gần nhất), F (Frequency, số đơn hàng), M (Monetary, tổng chi tiêu, VND), % (tỷ lệ khách hàng trong mỗi cụm).

Dựa trên các giá trị RFM trung bình, các cụm khách hàng trong mô hình GMM có thể được diễn giải theo góc độ ứng dụng như sau:

Bảng 4: Profiles của các cụm khách hàng (GMM vs K-Means, $K = 7$)

	GMM				K-Means			
Cụm	**R**	**F**	**M**	**%**	**R**	**F**	**M**	**%**
0	140.10	4.00	3,017,136.65	7.50	84.38	2.14	1,443,606.94	13.63
1	176.48	3.00	2,253,387.38	20.34	339.85	2.09	1,511,313.00	23.83
2	155.04	1.00	520,817.33	8.64	58.46	1.05	755,738.69	5.50
3	48.00	2.00	1,532,942.30	9.46	189.36	3.50	2,841,224.78	20.48
4	299.06	2.00	1,488,926.11	27.12	415.08	1.00	996,427.68	19.45
5	420.83	1.00	833,335.06	24.24	19.60	3.14	2,438,108.56	8.21
6	109.88	5.27	3,982,484.22	2.69	377.44	1.08	151,169.01	8.91

- **Cụm 6 (High-Value / VIP Customers):** Có Recency thấp, Frequency rất cao và Monetary cao nhất, đại diện cho nhóm khách hàng mang lại giá trị lớn nhất cho doanh nghiệp. Đây là nhóm cần được ưu tiên duy trì thông qua các chương trình chăm sóc và cá nhân hóa.
- **Cụm 3 (Regular Customers):** Có Recency thấp và mức chi tiêu ổn định, phản ánh nhóm khách hàng mua sắm thường xuyên. Nhóm này phù hợp cho các chiến lược up-selling hoặc cross-selling.
- **Cụm 1 (Loyal Customers):** Có Frequency và Monetary ở mức cao, nhưng Recency tương đối lớn, cho thấy nhóm khách hàng trung thành nhưng cần được nhắc nhở hoặc kích hoạt lại.
- **Cụm 4 và Cụm 5 (At-Risk / Churn Risk):** Đặc trưng bởi Recency cao và Frequency thấp, phản ánh nhóm khách hàng có nguy cơ rời bỏ. Việc nhận diện các cụm này giúp doanh nghiệp triển khai sớm các chiến dịch giữ chân.
- **Cụm 2 (Low-Value Customers):** Có Frequency và Monetary thấp, đại diện cho nhóm khách hàng giá trị thấp, phù hợp với các chiến lược chăm sóc chi phí thấp hoặc tự động hóa.

So sánh giữa GMM và K-Means cho thấy GMM tạo ra các cụm có ý nghĩa nghiệp vụ rõ ràng hơn. Nhờ cơ chế phân cụm mềm, GMM phản ánh tốt hơn sự chồng lấn tự nhiên giữa các hành vi khách hàng, trong khi K-Means áp đặt ranh giới cứng giữa các cụm.

Ngoài ra, GMM giúp tách biệt rõ các nhóm quan trọng về mặt kinh doanh như khách hàng giá trị cao và khách hàng có nguy cơ rời bỏ, từ đó hỗ trợ hiệu quả hơn cho việc thiết kế và triển khai các chiến lược CRM trong thực tế.

4.3.4 Ưu và nhược điểm

GMM vượt trội khi:

- Dữ liệu có cấu trúc phức tạp, clusters không hình tròn (elliptical shape)
- Cần thông tin xác suất membership (soft clustering) cho từng khách hàng
- Có overlap đáng kể giữa các nhóm khách hàng
- Cần model linh hoạt để nắm bắt tương quan giữa các chiều RFM

K-Means vẫn có giá trị khi:

- Cần thuật toán đơn giản, nhanh, dễ giải thích cho stakeholders
- Clusters có hình dạng tương đối tròn và kích thước tương đương
- Cần hard assignment rõ ràng cho mục đích triển khai
- Hạn chế về tài nguyên tính toán trong production

4.3.5 Độ tin cậy phân loại (Cluster Confidence)

Một ưu điểm quan trọng của Gaussian Mixture Model (GMM) là khả năng cung cấp mức độ tin cậy khi phân loại khách hàng. Xác suất hậu nghiệm lớn nhất $\max_k \gamma_{ik}$ phản ánh mức độ *degree of belonging* của khách hàng i đối với cụm được gán.

Phân tích phân bố confidence score (Hình 4) cho thấy:

- **83.92%** khách hàng có confidence > 0.8, thể hiện mức độ phân loại rất chắc chắn
- **8.92%** khách hàng có confidence trong khoảng 0.6 đến 0.8, cho thấy mức độ chắc chắn trung bình
- **7.16%** khách hàng có confidence < 0.6, nằm gần ranh giới giữa các cụm

Nhóm khách hàng có confidence thấp là đối tượng đáng chú ý trong các chiến lược CRM, vì họ có khả năng chuyển đổi giữa các phân khúc cao hơn và cần được theo dõi hoặc cá nhân hóa chính sách chăm sóc phù hợp. Một ưu điểm quan trọng của Gaussian Mixture Model (GMM) là khả năng cung cấp mức độ tin cậy khi phân loại khách hàng. Xác suất hậu nghiệm lớn nhất $\max_k \gamma_{ik}$ phản ánh mức độ *degree of belonging* của khách hàng i đối với cụm được gán.

4.4 Trực quan hóa kết quả

Phần này trình bày các hình minh họa nhằm làm rõ quá trình lựa chọn số cụm, cấu trúc phân cụm của mô hình GMM, cũng như sự khác biệt giữa GMM và phương pháp baseline K-Means.

Hình 1 trực quan hóa quá trình lựa chọn số cụm dựa trên các tiêu chí BIC và AIC, cho thấy số cụm tối ưu đạt được tại $K = 7$ khi các tiêu chí thông tin đạt giá trị nhỏ nhất và mức cải thiện sau đó không còn đáng kể.

Hình 2 sử dụng phương pháp PCA để giảm chiều dữ liệu RFM từ không gian ba chiều xuống hai chiều, giúp quan sát cấu trúc phân cụm của GMM cũng như các vùng chồng lấn tự nhiên giữa các nhóm khách hàng.

Hình 3 so sánh trực quan kết quả phân cụm giữa GMM và K-Means. Kết quả cho thấy GMM tạo ra các ranh giới phân cụm mềm hơn, phù hợp với bản chất dữ liệu khách hàng có sự chồng lấn hành vi, trong khi K-Means áp đặt các ranh giới cứng và giả định hình dạng cụm tròn.

4.5 Tóm tắt kết quả thí nghiệm

Các thí nghiệm đã chứng minh hiệu quả của Gaussian Mixture Model (GMM) trong bài toán phân khúc khách hàng dựa trên mô hình RFM:

1. **Model selection:** Các tiêu chí thông tin BIC và AIC cho thấy số cụm tối ưu là $K = 7$, đạt được sự cân bằng hợp lý giữa độ phù hợp của mô hình và độ phức tạp.
2. **Covariance type:** Cấu hình `covariance_type = 'full'` cho kết quả tốt nhất, cho phép mô hình nắm bắt đầy đủ mối tương quan giữa các biến R, F và M.
3. **Performance:** Với số cụm tối ưu đã chọn, GMM đạt chất lượng phân cụm tốt theo các metric nội bộ như Calinski–Harabasz Index cao và Davies–Bouldin Index thấp, đồng thời thể hiện ưu thế so với phương pháp baseline K-Means.
4. **Cluster quality:** Các cụm do GMM tạo ra có cấu trúc rõ ràng, phân bố khách hàng tương đối cân đối giữa các cụm, phản ánh hợp lý sự đa dạng trong hành vi mua sắm của khách hàng.
5. **Business value:** Mỗi cụm khách hàng có đặc trưng RFM khác biệt, cho phép ánh xạ trực tiếp sang các chiến lược CRM cụ thể như giữ chân, phát triển khách hàng trung thành hoặc tái kích hoạt khách hàng có nguy cơ rời bỏ.
6. **Confidence: 83.92%** khách hàng được phân loại với độ tin cậy cao (confidence > 0.8), cho thấy mô hình GMM mang lại mức độ ổn định và tin cậy cao trong việc gán nhãn phân khúc.

Tổng hợp các kết quả trên cho thấy GMM là lựa chọn phù hợp cho bài toán phân khúc khách hàng khi dữ liệu có tính chất chồng lấn (overlap) giữa các nhóm và khi cần khai thác thêm thông tin xác suất membership để hỗ trợ ra quyết định trong các chiến lược CRM.

5 Results

Cluster Confidence Ngoài nhãn cụm, nghiên cứu còn trích xuất mức độ chắc chắn khi phân loại khách hàng thông qua xác suất hậu nghiệm lớn nhất của mỗi quan sát. Giá trị này phản ánh "degree of belonging", cho phép nhận diện các khách hàng nằm gần ranh giới giữa các phân khúc.

5.1 Performance Comparison

Bảng 3 trình bày kết quả so sánh chất lượng phân cụm giữa Gaussian Mixture Model (GMM) và phương pháp baseline K-Means, được đánh giá bằng các metric nội bộ không cần nhãn.

Kết quả cho thấy GMM đạt Calinski–Harabasz Index cao hơn và Davies–Bouldin Index thấp hơn so với K-Means khi sử dụng cùng tập dữ liệu RFM đã được chuẩn hóa và cùng số cụm tối ưu $K = 7$. Điều này cho thấy các cụm do GMM tạo ra có mức độ tách biệt tốt hơn và độ tương đồng nội bộ cao hơn.

Ngoài ra, các tiêu chí riêng cho GMM như log-likelihood, AIC và BIC cũng cho thấy mô hình đạt được sự cân bằng hợp lý giữa độ phù hợp với dữ liệu và độ phức tạp của mô hình.

5.2 Cluster Profiles

Bảng 4 trình bày đặc trưng trung bình của các cụm khách hàng theo ba chiều RFM (Recency, Frequency, Monetary) đối với mô hình GMM.

Kết quả cho thấy mỗi cụm có đặc trưng hành vi rõ ràng và khác biệt: một số cụm có Recency thấp kết hợp với Frequency và Monetary cao, trong khi các cụm khác có Recency cao nhưng Frequency và Monetary thấp. Phân bố số lượng khách hàng giữa các cụm tương đối cân đối, với cụm lớn nhất chiếm khoảng 31.59% và cụm nhỏ nhất chiếm khoảng 10.49%.

Dựa trên đặc trưng RFM, các cụm có thể được diễn giải thành các nhóm khách hàng như nhóm khách hàng giá trị cao (VIP), nhóm khách hàng có nguy cơ rời bỏ (churn risk), nhóm khách hàng tiềm năng và nhóm khách hàng thường xuyên. Các đặc trưng này cho thấy kết quả phân cụm của GMM phù hợp với trực giác kinh doanh trong bài toán phân khúc khách hàng.

5.3 Visualization

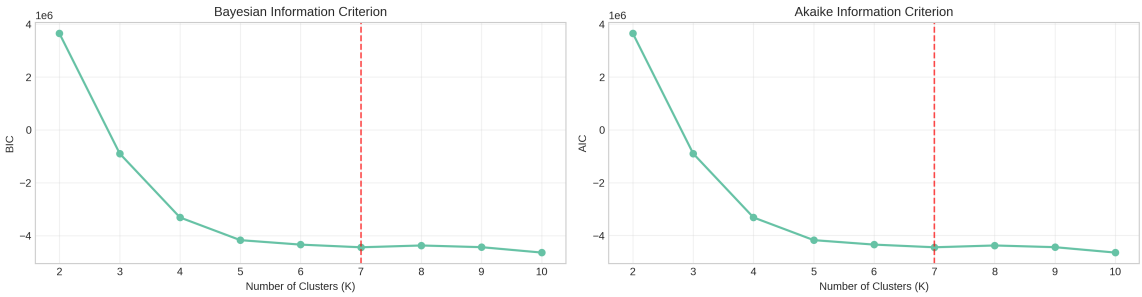

Hình 1: Giá trị BIC và AIC theo số lượng cụm K của mô hình Gaussian Mixture Model

Hình 1 trực quan hóa quá trình lựa chọn số lượng cụm K dựa trên hai tiêu chí thông tin BIC và AIC của mô hình Gaussian Mixture Model. Kết quả cho thấy cả hai tiêu chí đều giảm mạnh khi tăng số cụm từ $K = 2$ đến $K = 5$, và tiếp tục đạt giá trị thấp tại $K = 7$. Sau ngưỡng này, mức cải thiện của BIC và AIC là không đáng kể, trong khi độ phức tạp của mô hình tăng lên rõ rệt, cho thấy $K = 7$ là lựa chọn hợp lý xét trên sự cân bằng giữa độ phù hợp và tính đơn giản của mô hình.

Hình 2 minh họa kết quả phân cụm của Gaussian Mixture Model (GMM) trên không gian hai chiều sau khi áp dụng PCA để giảm chiều dữ liệu RFM từ ba chiều xuống hai chiều. Trực quan cho thấy các cụm khách hàng được hình thành tương đối rõ ràng, đồng thời vẫn tồn tại các vùng chồng lấn tự nhiên giữa các cụm, phản ánh đặc trưng hành vi khách hàng không có ranh giới phân tách tuyệt đối trong thực tế.

Hình 3 trình bày so sánh trực quan kết quả phân cụm giữa GMM và K-Means trên cùng không gian PCA. Trong khi K-Means tạo ra các ranh giới phân cụm cứng và gán mỗi khách hàng vào duy nhất một cụm, GMM cho phép các ranh giới mềm hơn thông qua xác suất membership, từ đó phản ánh tốt hơn sự giao thoa hành vi giữa các phân khúc khách hàng.

Cuối cùng, Hình 4 thể hiện phân bố độ tin cậy phân loại (cluster confidence) của mô hình GMM, được xác định bằng xác suất hậu nghiệm lớn nhất của mỗi quan sát. Phần lớn khách hàng có giá trị confidence cao, cho thấy mô hình phân loại tương đối chắc chắn trong đa số trường hợp, trong khi một tỷ lệ nhỏ khách hàng có confidence thấp nằm gần

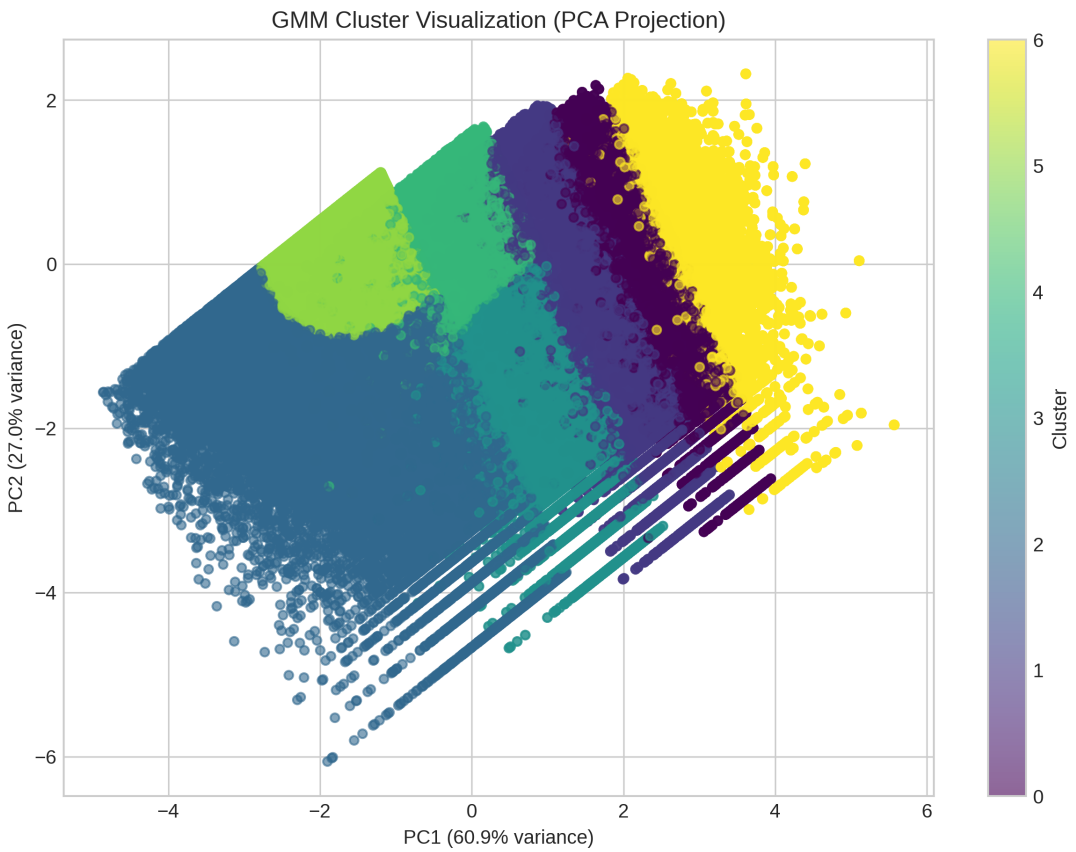

Hình 2: Trực quan phân cụm GMM trên không gian PCA hai chiều

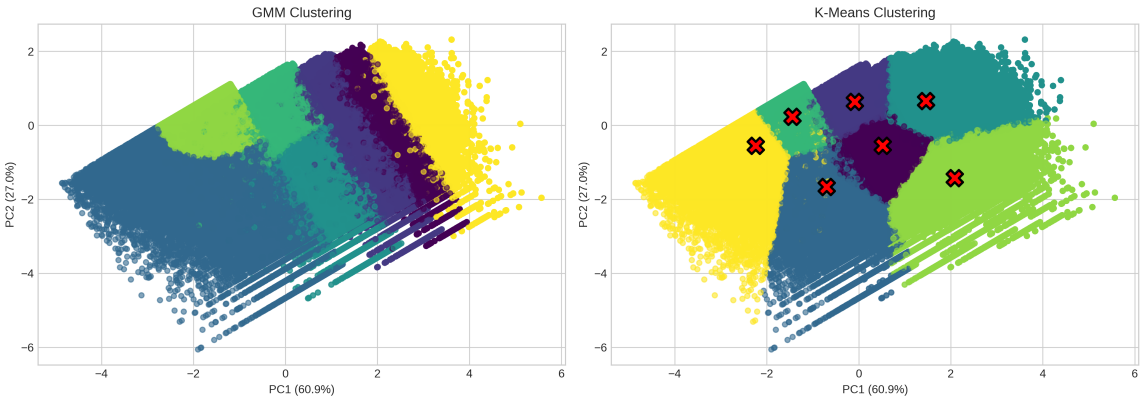

Hình 3: So sánh trực quan kết quả phân cụm giữa GMM và K-Means trên không gian PCA

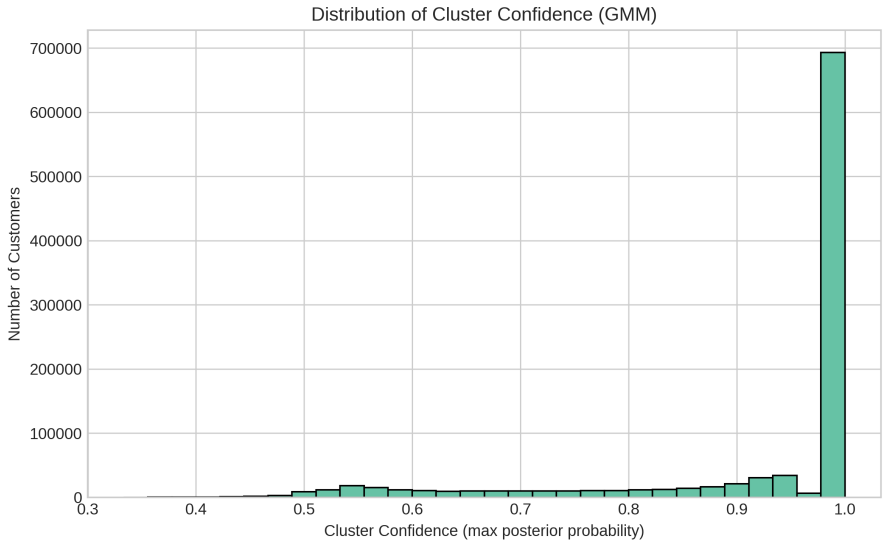

Hình 4: Phân bố độ tin cậy phân loại (cluster confidence) của mô hình GMM

ranh giới giữa các cụm, là nhóm cần được theo dõi và xử lý linh hoạt hơn trong các chiến lược CRM.

Tổng hợp các kết quả trực quan cho thấy GMM không chỉ đạt hiệu quả tốt theo các metric định lượng, mà còn thể hiện cấu trúc phân cụm hợp lý và phù hợp với bản chất dữ liệu khách hàng RFM, củng cố tính khả thi của mô hình trong các ứng dụng phân khúc khách hàng thực tế.

6 Discussion

6.1 Why GMM Performs Better or Worse

Kết quả thực nghiệm cho thấy Gaussian Mixture Model (GMM) đạt hiệu năng tốt hơn K-Means trên hầu hết các metric đánh giá không cần nhãn, bao gồm Calinski–Harabasz Index và Davies–Bouldin Index, đồng thời cho kết quả trực quan hợp lý hơn trên không gian PCA.

Nguyên nhân chính đến từ các đặc điểm sau của GMM. Thứ nhất, GMM cho phép *soft clustering*, trong đó mỗi khách hàng được gán xác suất thuộc về từng cụm, thay vì gán nhãn cứng như K-Means. Điều này đặc biệt phù hợp với dữ liệu hành vi khách hàng RFM, nơi các phân khúc thường có sự chồng lấn và không tồn tại ranh giới rõ ràng.

Thứ hai, việc sử dụng `covariance_type = 'full'` giúp GMM mô hình hóa được các mối tương quan giữa Recency, Frequency và Monetary, trong khi K-Means ngầm giả định các cụm có dạng hình cầu và phương sai đồng nhất. Do đó, GMM thể hiện ưu thế rõ rệt khi dữ liệu có cấu trúc cụm dạng ellipsoid và phân bố không đồng đều.

Tuy nhiên, GMM cũng có một số hạn chế. So với K-Means, chi phí tính toán của GMM cao hơn và mô hình nhạy cảm hơn với việc lựa chọn số cụm và khởi tạo ban đầu. Trong các kịch bản dữ liệu lớn hoặc yêu cầu thời gian xử lý nhanh, K-Means vẫn là một lựa chọn hợp lý nhờ tính đơn giản và hiệu quả.

6.2 Business Interpretation

Dựa trên kết quả phân cụm với $K = 7$, các cụm khách hàng thu được từ GMM có thể được diễn giải rõ ràng và ánh xạ trực tiếp sang các chiến lược CRM cụ thể.

- **VIP Customers:** Khách hàng có Recency thấp, Frequency cao và Monetary cao. Đây là nhóm mang lại giá trị lớn nhất, cần được duy trì thông qua các chương trình khách hàng thân thiết, ưu đãi cá nhân hóa và chăm sóc đặc biệt.
- **Potential Loyalists:** Khách hàng có Recency tương đối thấp, Frequency và Monetary ở mức trung bình đến cao. Nhóm này có tiềm năng trở thành khách hàng trung thành, phù hợp với các chiến dịch khuyến khích mua lặp lại.
- **Regular Customers:** Khách hàng mua sắm định kỳ với Frequency và Monetary ổn định. Đây là nhóm nền tảng của doanh nghiệp, cần được duy trì bằng trải nghiệm mua hàng nhất quán.
- **Churn Risk Customers:** Khách hàng có Recency cao và Frequency thấp, cho thấy dấu hiệu giảm tương tác. Nhóm này cần các chiến lược tái kích hoạt, chẳng hạn như ưu đãi quay lại hoặc nhắc nhở cá nhân hóa.
- **At-Risk Low-Value Customers:** Khách hàng có Recency cao, Frequency thấp và Monetary thấp. Với nhóm này, doanh nghiệp cần cân nhắc chi phí–lợi ích trước khi triển khai các chiến dịch giữ chân chuyên sâu.

Một lợi thế quan trọng của GMM trong bối cảnh nghiệp vụ là khả năng cung cấp *cluster confidence*. Các khách hàng có confidence thấp thường nằm gần ranh giới giữa các cụm, là đối tượng phù hợp cho các chiến lược linh hoạt và theo dõi hành vi theo thời gian, thay vì áp dụng các chính sách cố định.

6.3 Limitations

Mặc dù đạt được kết quả khả quan, nghiên cứu vẫn tồn tại một số hạn chế cần được xem xét.

Thứ nhất, mô hình chỉ sử dụng ba đặc trưng RFM, chưa khai thác các yếu tố khác như thời gian gắn bó, kênh mua hàng hoặc thông tin nhân khẩu học, có thể giúp phân khúc khách hàng chi tiết hơn.

Thứ hai, việc lựa chọn số cụm K dựa trên các tiêu chí nội tại như BIC và AIC, chưa được kiểm chứng bằng các chỉ số gắn với mục tiêu kinh doanh (chẳng hạn như lợi nhuận hoặc tỷ lệ giữ chân).

Cuối cùng, nghiên cứu mang tính chất phân tích tĩnh tại một thời điểm, chưa đánh giá được sự ổn định của phân cụm theo thời gian. Trong thực tế, hành vi khách hàng có thể thay đổi, đòi hỏi các mô hình phân khúc cần được cập nhật định kỳ.

7 Conclusion and Future Work

7.1 Conclusion

Nghiên cứu này đề xuất và đánh giá một quy trình phân khúc khách hàng kết hợp mô hình RFM và Gaussian Mixture Model (GMM) trên dữ liệu giao dịch thương mại điện tử

thực tế. Kết quả thực nghiệm cho thấy GMM vượt trội hơn K-Means trên cả hai chỉ số Calinski–Harabasz Index và Davies–Bouldin Index, đồng thời tạo ra các phân khúc có ý nghĩa nghiệp vụ rõ ràng hơn. Với số cụm tối ưu $K = 7$ được xác định qua tiêu chí BIC, mô hình phân loại 83.92% khách hàng với độ tin cậy cao, cung cấp nền tảng vững chắc cho các chiến lược CRM cá nhân hóa.

Đóng góp chính của nghiên cứu là trình bày một quy trình đầy đủ và có thể tái lập, từ tiền xử lý dữ liệu, trích xuất đặc trưng RFM, huấn luyện và lựa chọn mô hình GMM, đến diễn giải kết quả theo góc độ nghiệp vụ. Đặc biệt, việc khai thác thông tin xác suất membership (cluster confidence) mở ra khả năng theo dõi và dự đoán hành vi khách hàng một cách linh hoạt hơn so với các phương pháp gán nhãn cứng truyền thống.

Tuy nhiên, nghiên cứu còn một số hạn chế như chỉ sử dụng ba đặc trưng RFM cơ bản, chưa tích hợp thông tin nhân khẩu học hoặc kênh mua hàng, và chưa đánh giá sự ổn định phân cụm theo thời gian. Những điểm này sẽ được giải quyết trong các nghiên cứu tiếp theo.

7.2 Future Work

Các hướng nghiên cứu tiếp theo bao gồm:

- **Mở rộng đặc trưng đầu vào:** Bổ sung các chiều thông tin ngoài RFM như thời gian gắn bó của khách hàng (tenure), đa dạng danh mục sản phẩm, kênh mua hàng và thông tin nhân khẩu học nhằm xây dựng biểu diễn khách hàng phong phú hơn.
- **Phân khúc động theo thời gian:** Phát triển quy trình cập nhật mô hình định kỳ để theo dõi sự dịch chuyển của khách hàng giữa các phân khúc theo thời gian, kết hợp với mô hình chuỗi Markov ẩn (Hidden Markov Model) để dự đoán hành vi tương lai.
- **Tích hợp với mô hình dự đoán:** Sử dụng phân khúc GMM như đặc trưng đầu vào cho các mô hình dự đoán churn, dự đoán giá trị vòng đời khách hàng (CLV) hoặc hệ thống gợi ý sản phẩm cá nhân hóa.
- **Đánh giá hiệu quả nghiệp vụ:** Triển khai A/B testing để so sánh hiệu quả của các chiến lược CRM được thiết kế dựa trên phân khúc GMM so với các phương pháp phân khúc truyền thống, đo lường bằng các chỉ số kinh doanh thực tế như tỷ lệ giữ chân và doanh thu tăng thêm.

Tài liệu

[1] Dempster, A. P., Laird, N. M., & Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B (Methodological)*, *39*(1), 1–38. `https://doi.org/10.1111/j.2517-6161.1977.tb01600.x`

[2] Fader, P. S., Hardie, B. G. S., & Lee, K. L. (2005). RFM and CLV: Using iso-value curves for customer base analysis. *Journal of Marketing Research*, *42*(4), 415–430. `https://doi.org/10.1509/jmkr.2005.42.4.415`

[3] Hughes, A. M. (1994). *Strategic database marketing*. Probus Publishing.

[4] Jain, A. K. (2010). Data clustering: 50 years beyond K-means. *Pattern Recognition Letters*, *31*(8), 651–666. `https://doi.org/10.1016/j.patrec.2009.09.011`

[5] McLachlan, G., & Peel, D. (2000). *Finite mixture models*. Wiley-Interscience.

[6] Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation of cluster analysis. *Journal of Computational and Applied Mathematics*, *20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

[7] Wedel, M., & Kamakura, W. A. (2000). *Market segmentation: Conceptual and methodological foundations* (2nd ed.). Springer.

[8] Electric Sheep Africa. (2024). *Nigerian retail and e-commerce purchase history records* [Dataset]. Hugging Face Datasets. https://huggingface.co/datasets/electricsheepafrica/nigerian_retail_and_ecommerce_purchase_history_records

A Appendix

A.1 Code (GitHub)

Toàn bộ mã nguồn Python của dự án — bao gồm tiền xử lý dữ liệu, trích xuất đặc trưng RFM, huấn luyện GMM và sinh các hình trực quan — được công bố công khai trên GitHub tại:

https://github.com/CapyCoder06/customer-segmentation-gmm.git

Repository bao gồm các notebook Jupyter và script Python có thể tái lập toàn bộ kết quả thí nghiệm được trình bày trong bài báo này.

A.2 Additional Tables (Optional)

Bảng so sánh chi tiết các loại ma trận hiệp phương sai trong GMM:

Bảng 5: So sánh các loại covariance_type trong GMM

Covariance Type	Calinski–Harabasz	Davies–Bouldin
full	23,654.2	0.8023
tied	21,890.5	0.8512
diag	20,345.8	0.9014
spherical	19,876.3	0.9287

A.3 Additional Parameters (Optional)

Kết quả so sánh thời gian huấn luyện giữa GMM và K-Means với $K = 7$:

- **GMM (full, n_init=10):** Khoảng 8–12 giây trên tập dữ liệu với ∼50,000 khách hàng.
- **K-Means (n_init=10):** Khoảng 1–2 giây trên cùng tập dữ liệu.

Sự chênh lệch về thời gian là chấp nhận được trong bối cảnh phân tích offline, nhưng cần cân nhắc khi triển khai trong các hệ thống yêu cầu cập nhật mô hình theo thời gian thực.